

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

DEPARTAMENTO DE FÍSICA

Física Computacional - FIS205

Profesores: Ariel Norambuena, Nicolás Viaux

Ayudante: Cristóbal Benavides

Tarea 2

Nombre del Estudiante: Jorge Ruiz de Viñaspre

Problema 1: Inteligencia artificial para problemas inversos

En este problema se aborda la inferencia de los parámetros físicos $\theta = (\gamma, k)$ de un oscilador armónico amortiguado regido por la ecuación $m\ddot{x}(t) + \gamma\dot{x}(t) + kx(t) = 0$, utilizando modelos de regresión de aprendizaje automático.

a) Conceptos Clave

- **Problema directo e inverso:** En el problema directo, los parámetros físicos (γ, k) son la entrada y se determina la trayectoria del sistema $x(t)$ mediante integración matemática. La dificultad intrínseca del problema inverso (inferir γ y k a partir de $x(t)$) radica en que suele estar mal condicionado, pudiendo haber alta sensibilidad al ruido en la señal o ambigüedad matemática donde múltiples pares de parámetros generan señales temporales similares.
- **Aprendizaje supervisado:** Sí, es estrictamente necesario conocer las etiquetas reales durante el entrenamiento. El modelo requiere el conjunto de datos acoplado $\{(x_i, \theta_i)\}_{i=1}^N$, porque aprende ajustando sus pesos internos basándose en la discrepancia entre su predicción y el valor real del label $\theta_i = (\gamma_i, k_i)$. Sin los labels, no se puede calcular el error para guiar la optimización. Alternativamente, se podría plantear una PINN que considerase la ecuación de oscilador armónico en la función de pérdida, lo que reduciría la necesidad de supervisión del entrenamiento.
- **Conjuntos de entrenamiento y validación:** Se separan los datos para evaluar la capacidad de generalización del modelo. El subconjunto de *train* se usa para ajustar los parámetros internos de la red, mientras que el subconjunto de *test* actúa como datos "nunca antes vistos", permitiendo detectar si el modelo está memorizando el ruido (*overfitting*) o si realmente aprendió el fenómeno subyacente. Para evaluar este efecto, se revisa la diferencia entre la pérdida durante el entrenamiento $Loss_{train}$, contra la pérdida de evaluación $Loss_{test}$.
- **Función de pérdida:** Es necesario definir una métrica como el Error Cuadrático Medio ($MSE = \frac{1}{N} \sum_{i=1}^N [(\gamma_i - \hat{\gamma}_i)^2 + (k_i - \hat{k}_i)^2]$), porque cuantifica matemáticamente el rendimiento del modelo. Al ser diferenciable, el MSE permite utilizar el algoritmo de (*backpropagation*) y el descenso de gradiente para minimizar el error de forma iterativa.

b) Generación de Datos y Efectos de los Parámetros

Se generaron $N = 3000$ señales resolviendo la ecuación diferencial mediante el método de Runge-Kutta explícito (`solve_ivp`). Al analizar las series temporales y variar los parámetros, se observa lo siguiente:

- **Efecto de la constante elástica (k):** Modifica principalmente la frecuencia angular de oscilación del sistema. Valores mayores de k resultan en oscilaciones más frecuentes.
- **Efecto del amortiguamiento (γ):** Dicta la tasa de decaimiento exponencial de la amplitud de la señal. Un γ mayor acelera el decaimiento en la envolvente, reduciendo el movimiento transitorio en menos tiempo.




Figura 1: 3 Señales oscilatorias y amortiguadas generadas, obtenidas con RK45.

c) Entrenamiento de Modelos

Los modelos elegidos para la regresión fueron un ensamblado de árboles de decisión (`RandomForestRegressor`) y un perceptrón multicapa (`MLPRegressor` mediante `PyTorch`), con funciones de activación `ReLU()`.

d) Efecto del Ruido Estadístico y Sobreajuste

Al introducir ruido gaussiano con desviación estándar variable $\sigma = \{0, 0.01, 0.02, 0.05, 0.10\}$, se aprecia degradamiento en la capacidad predictiva de los modelos. Se calcula el RMSE para ambos modelos, se reportan dichas cantidades obtenidas para las predicciones del entrenamiento y testeo:

Al analizar los gráficos y las métricas tabuladas previamente, podemos extraer dos conclusiones fundamentales solicitadas en el problema:

1. Dificultad relativa de inferencia (γ vs k)

Determinar cuál parámetro es más difícil de inferir requiere considerar la magnitud del error respecto al rango original de los parámetros ($\gamma \in [0.05, 1.0]$ con rango 0.95; $k \in [1.0, 5.0]$ con rango 4.0).

Nivel de Ruido (σ)	RMSE γ		RMSE k	
	Entrenamiento	Testeo	Entrenamiento	Testeo
0.00	0.0042	0.0099	0.0047	0.0099
0.01	0.0054	0.1190	0.0364	0.0539
0.02	0.0070	0.0154	0.0224	0.0453
0.05	0.0135	0.0301	0.0220	0.0593
0.10	0.0246	0.0569	0.0408	0.1137

Cuadro 1: Resultados de RMSE para el modelo Random Forest bajo distintos niveles de ruido gaussiano.

Nivel de Ruido (σ)	RMSE γ		RMSE k	
	Entrenamiento	Testeo	Entrenamiento	Testeo
0.00	0.0118	0.0122	0.0137	0.0145
0.01	0.0119	0.0126	0.0334	0.0357
0.02	0.0085	0.0101	0.0313	0.0338
0.05	0.0303	0.0351	0.0340	0.0464
0.10	0.0086	0.0290	0.0192	0.0800

Cuadro 2: Resultados de RMSE para la Red Neuronal (MLP) bajo distintos niveles de ruido gaussiano.




Figura 2: RMSE para γ y k según los distintos σ

Aunque en términos absolutos el $RMSE_k$ alcanza valores mayores (hasta $\sim 0,11$ para Random Forest en $\sigma = 0,10$), proporcionalmente a su dominio, el parámetro γ resulta ser más difícil de inferir bajo condiciones ruidosas.

Analizándolo cualitativamente desde la física, se pueden plantear los siguientes puntos que avalan los resultados obtenidos:

Físicamente, esto se explica por el rol de cada parámetro en la señal temporal:

- La constante elástica (k) describe la frecuencia de oscilación, la cual es difícilmente alterada por el ruido gaussiano añadido a la señal.
- El amortiguamiento (γ) define la envolvente de decaimiento exponencial. A medida que la amplitud real de la señal disminuye con el tiempo, la proporción señal-ruido cae drásticamente. El puede sobrellevar a la señal en la cola de esta, impidiendo que los algoritmos capturen la tasa de decaimiento correcta.

2. Manifestación del Sobreajuste (Overfitting)

El sobreajuste ocurre cuando un modelo memoriza el ruido estadístico particular de los datos de entrenamiento en lugar de aprender la relación subyacente que mapea la trayectoria temporal a los parámetros físicos.

En nuestros resultados tabulados, este fenómeno se manifiesta como una brecha sustancial entre los errores de entrenamiento y testeo, siendo particularmente severo en el modelo Random Forest. Este fenómeno se ve principalmente reflejado en los datos obtenidos para el Random Forest 1 para γ en $\sigma = 0,01$, con un error de testeo ~ 22 veces mayor; y en la fila $\sigma = 0,10$, donde el error de testeo de k es ~ 3 veces mayor.

Por el contrario, como se observa en la Figura 2, la red neuronal MLP en PyTorch demuestra ser más regularizada y resiliente ante la inyección de ruido, logrando contener el aumento del error de testeo de manera mucho más suave, particularmente visible en la inferencia de k , donde su curva se mantiene consistentemente por debajo de la del Random Forest.